

Fun Physics — 生成式擴散模型的物理

Wen Perng 彭琨

2026 IPhOC 暑期物理研習營

2026/07/28

於2020年發布的 Denoising Diffusion Probabilistic Models (DDPM) [HJA20] 開啓了擴散模型的大門。其透過

正序加噪音： $q(\mathbf{x}_t|\mathbf{x}_{t-1}) = \mathcal{N}\left(\mathbf{x}_t; \overbrace{\sqrt{1-\beta_t}\mathbf{x}_{t-1}}^{\text{平均值}}, \overbrace{\sqrt{\beta_t}\mathbb{1}}^{\text{變異數}}\right)$ 、

反序除噪音： $p_\theta(\mathbf{x}_{t-1}|\mathbf{x}_t) = \mathcal{N}(\mathbf{x}_{t-1}; \boldsymbol{\mu}_\theta(\mathbf{x}_t, t), \Sigma_\theta(\mathbf{x}_t, t))$

兩過程生成極為擬真的影像。




圖: DDPM。圖源: Figure 2 [HJA20]。

然而，有幾個問題值得我們詢問：

- ▶ 反序除噪是逆熵過程，要如何實現？和物理的關聯是？
- ▶ 在這過程中，機器學習在學什麼？
- ▶ 怎樣的生成結果算好？

我們將透過隨機微積分的工具，從朗之萬動力學的角度切入擴散模型 [SE20]，並引入 score 的概念去介紹。

以下之討論主要參考 [HJA20] 和 [FW26]，並使用 [T26] 中的數學工具。

1 機率分布之間的變動

■ 隨機微分方程 ■ 常微分方程

2 擴散模型與朗之萬動力學

3 Score-Based 生成式擴散模型

4 結語



布朗運動為一隨機過程(random process)

$$W_{t+\Delta t} = W_t + \sqrt{\Delta t} Z_t, \quad Z_t \stackrel{\text{i.i.d.}}{\sim} \mathcal{N}(0, 1), \quad (1)$$

其又稱為「維納過程(Wiener process)」。 $\circ$ 上式亦可表示為

$$dW_t = W_{t+dt} - W_t \sim \mathcal{N}(0, dt \cdot 1). \quad (2)$$

其中 $\mathcal{N}(0, dt \cdot 1)$ 為平均值為 0 、變異數為 dt 的高斯分布。



若加上飄移：

$$d\mathbf{X}_t = \underbrace{\mathbf{f}_t dt}_{\text{飄移}} + \underbrace{\sigma_t d\mathbf{W}_t}_{\text{擴散}} \quad (3)$$

且 $\mathbf{X}_0 = \mathbf{0}$ ，則有

$$\mathbf{X}_t \sim \mathcal{N} \left(\int_0^t \mathbf{f}_s ds, \mathbb{I} \int_0^t \sigma_s^2 ds \right) \circ \quad (4)$$

伊藤清(Itō Kiyoshi)則提供了較為廣義的「伊藤過程」：

$$d\mathbf{X}_t = \mathbf{f}(\mathbf{X}_t, t)dt + \Sigma_t d\mathbf{W}_t \circ \quad (5)$$

注意！我們稱以上全微分為「隨機微分方程(stochastic differential equation)」。
另外，我們以下討論中都侷限於 $\Sigma_t = \sigma_t \mathbb{I}$ 。

微分形式僅表達了伊藤隨機過程的部分性質，另一部分(即 dW_t 究竟是什麼?)須從積分形式觀察：

1. $(dt)^2 = 0$ 。
2. $dt \cdot dW_t = 0$ 。
3. $\boxed{(dW_t)^2 = dt}$ 。

茲概念如下：

$$\int_0^T dW_t^2 = \lim_{N \rightarrow \infty} \sum_{k=0}^{N-1} (\Delta W_{t_k})^2 = \lim_{N \rightarrow \infty} Q_N$$

$$\Delta W_{t_k} \stackrel{\text{i.i.d.}}{\sim} \mathcal{N}(0, \Delta t)$$

$$\therefore \begin{cases} \mathbb{E}[Q_N] = N\Delta t = T \\ \text{Var}(Q_N) = 2N(\Delta t)^2 = 2T\Delta t \end{cases}$$

$$\therefore Q_N \xrightarrow{L^2} T \Rightarrow \int_0^T dW_t^2 = T \Rightarrow (dW_t)^2 = dt。$$



(實際上需驗證 $\int f_t dW_t^2 = \int f_t dt$ 。)

對於任兩座標 j 、 k 有

$$dW_t^{(j)} \cdot dW_t^{(k)} = \delta_{jk} dt. \quad (6)$$

故有以下引理：

引理. (伊藤引理)

考慮隨機過程 $\mathbf{X}_{0:T}$ 滿足隨機微分方程

$$d\mathbf{X}_t = \mathbf{f}(\mathbf{X}_t, t)dt + \Sigma_t d\mathbf{W}_t. \quad (7)$$

對於純量函數 $\phi : \mathbb{R}^n \times [0, T] \rightarrow \mathbb{R}$ ，其全微分爲

$$d\phi(\mathbf{X}_t, t) = (\nabla \phi)^\top d\mathbf{X}_t + \frac{1}{2}(d\mathbf{X}_t)^\top H_\phi d\mathbf{X}_t + \frac{\partial \phi}{\partial t} dt \quad (8)$$

$$= \left(\frac{\partial \phi}{\partial t} + (\nabla \phi)^\top \mathbf{f} + \frac{1}{2} \text{Tr} \left\{ \Sigma_t^\top H_\phi \Sigma_t \right\} \right) dt + (\nabla \phi)^\top \Sigma_t d\mathbf{W}_t. \quad (9)$$

要了解隨機過程在一給定的隨機微分方程下的行為，最直觀的方法是看其機率分布的變化，福克-普朗克(Fokker-Planck)方程式即提供我們這一橋梁。

定理. (福克-普朗克方程式)

考慮隨機過程 $\mathbf{X}_{0:T}$ 滿足隨機微分方程

$$d\mathbf{X}_t = \mathbf{f}(\mathbf{X}_t, t)dt + \sigma_t d\mathbf{W}_t, \quad (10)$$

則其機率密度函數 $\mathbf{X}_t \sim p_t$ 滿足福克-普朗克方程式：

$$\frac{\partial}{\partial t} p(\mathbf{x}, t) = -\nabla \cdot (\mathbf{f}(\mathbf{x}, t)p(\mathbf{x}, t)) + \frac{\sigma_t^2}{2} \nabla^2 p(\mathbf{x}, t). \quad (11)$$

此式可視為「連續方程式」和「擴散方程式」的整合。

其證明透過將機率密度函數與一測試函數積分得知其性質，該技巧與廣義函數理論中諸多算子性質證明相似。在過程中同時使用了伊藤引理。考慮測試函數 $\phi(\mathbf{x})$ 並考慮積分區間為 $\mathbb{R}^n$ ，

$$\begin{aligned}
 \mathbb{E}[\mathrm{d}\phi(\mathbf{X}_t)] &= \mathbb{E}\left[(\nabla\phi)^\top \mathbf{f} + \frac{\sigma_t^2}{2} \mathrm{Tr}\{H_\phi\}\right] \mathrm{d}t + \cancel{\mathbb{E}\left[\sigma_t(\nabla\phi)^\top \mathrm{d}\mathbf{W}_t\right]}^0 \\
 \Rightarrow \frac{\partial}{\partial t} \mathbb{E}[\phi(\mathbf{X}_t)] &= \mathbb{E}\left[(\nabla\phi)^\top \mathbf{f} + \frac{\sigma_t^2}{2} \nabla^2 \phi\right] \\
 \Rightarrow \frac{\partial}{\partial t} \int \phi(\mathbf{X}_t(\omega)) \mathrm{d}\mathbb{P}(\omega) &= \int (\nabla\phi)^\top \mathbf{f} p_t \mathrm{d}\mathbf{x} + \frac{\sigma_t^2}{2} \int \nabla^2 \phi p_t \mathrm{d}\mathbf{x} \\
 \Rightarrow \frac{\partial}{\partial t} \int \phi(\mathbf{x}) p_t(\mathbf{x}) \mathrm{d}\mathbf{x} &= - \int \phi \nabla \cdot (\mathbf{f} p_t) \mathrm{d}\mathbf{x} + \frac{\sigma_t^2}{2} \int \phi \nabla^2 p_t \mathrm{d}\mathbf{x} \circ \quad \blacksquare
 \end{aligned}$$

使用常微分方程亦可產生同樣的機率分布流。




圖: PF-ODE。圖源: Figure 2 [SSKKEP21]

定理. (機率流常微分方程 Probability Flow ODE)

考慮隨機微分方程

$$d\mathbf{X}_t = \mathbf{f}(\mathbf{X}_t, t)dt + \sigma_t d\mathbf{W}_t, \quad (12)$$

其中 $\mathbf{X}_0 \sim p_0$ ，透過福克-普朗克方程式可得 $\mathbf{X}_t \sim p_t$ 。則常微分方程

$$d\mathbf{X}_t = \left(\mathbf{f}(\mathbf{X}_t, t) - \frac{\sigma_t^2}{2} \nabla \log p_t(\mathbf{X}_t) \right) dt \quad (13)$$

亦有 $\mathbf{X}_t$ 滿足同樣的機率分布 p_t 。

Yang Song (宋颺)等提出了 PF-ODE 的方法 [SSKKEP21]，透過常微分方程去抽樣生成式模型，其優勢為

- ▶ 模擬步長可以較大或可用 ODE 數值方法加速，跑起來更快，如 [SME22; LZBCLZ22]；
- ▶ 生成影像與初始噪音為一對一，適用於影像編輯的任務 [CVSC22]，

然而其

- ▶ 缺少了噪音的修正，誤差易累積，產生帶有不自然瑕疵的影像。

若要移除微分方程中的布朗運動但維持其機率密度函數，則需要將福克-普朗克方程式中的擴散項移入到飄移項內：

$$\begin{aligned}\frac{\partial}{\partial t}p(\mathbf{x}, t) &= -\nabla \cdot (\mathbf{f}(\mathbf{x}, t)p(\mathbf{x}, t)) + \frac{\sigma_t^2}{2}\nabla^2 p(\mathbf{x}, t) \\ &= -\nabla \cdot \left(\mathbf{f}_t p_t - \frac{\sigma_t^2}{2} \nabla p_t \right) \\ &= -\nabla \cdot \left(\left(\mathbf{f}_t - \frac{\sigma_t^2}{2} \frac{\nabla p_t}{p_t} \right) p_t \right) \\ &= -\nabla \cdot \left(\left(\mathbf{f}_t - \frac{\sigma_t^2}{2} \nabla \log p_t \right) p_t \right) \circ\end{aligned}$$

透過對連續方程式的了解，我們可以立即認出每個點的速度場為

$$\frac{d}{dt}\mathbf{X}_t = \mathbf{f}(\mathbf{X}_t, t) - \frac{\sigma_t^2}{2} \nabla \log p_t(\mathbf{X}_t) \circ \blacksquare$$

- 1 機率分布之間的變動
- 2 擴散模型與朗之萬動力學
 - 逆轉隨機微分方程的時間 ■ 朗之萬動力學
- 3 Score-Based 生成式擴散模型
- 4 結語

定理. (伊藤過程的時間反演)

考慮隨機過程 $\mathbf{X}_{0:T}$ 滿足隨機微分方程

$$d\mathbf{X}_t = \mathbf{f}(\mathbf{X}_t, t)dt + \sigma_t d\mathbf{W}_t. \quad (14)$$

若定義 $p_t(\mathbf{x})$ 為 $\mathbf{X}_t$ 的機率分布，則有時間反演過程 $\widetilde{\mathbf{X}}_s := \mathbf{X}_{T-s}$ 滿足以下隨機微分方程：

$$d\widetilde{\mathbf{X}}_s = \left(-\mathbf{f}(\widetilde{\mathbf{X}}_s, T-s) + \sigma_{T-s}^2 \nabla \log p(\widetilde{\mathbf{X}}_s, T-s) \right) ds + \sigma_{T-s} d\widetilde{\mathbf{W}}_s, \quad (15)$$

其中 $\widetilde{\mathbf{W}}_s$ 為時間反演下的布朗運動。

梯度項 $\mathbf{s} = \nabla \log p$ 被稱為「score」。

證明：伊藤過程的時間反演 (略)

欲了解隨機過程在時間反演下的變化，觀察其機率密度函數最直接：從福克-普朗克方程式 $\partial_t p_t = -\nabla \cdot (\mathbf{f}_t p_t) + \sigma_t^2 \nabla^2 p_t / 2$ ，我們有

$$\frac{\partial}{\partial s} \underbrace{p(\mathbf{x}, T-s)}_{\tilde{p}_s(\mathbf{x})} = \nabla \cdot \left(\mathbf{f}(\mathbf{x}, T-s) p(\mathbf{x}, T-s) \right) - \frac{\sigma_{T-s}^2}{2} \nabla^2 p(\mathbf{x}, T-s) \circ$$

上式需等於時間反演隨機微分方程 $d\widetilde{\mathbf{X}}_s = \widetilde{\mathbf{f}}(\widetilde{\mathbf{X}}_s, s)ds + \sigma_{T-s}d\widetilde{\mathbf{W}}_s$ 對應到的福克-普朗克方程式。代入定理的猜解即可驗證：

$$\begin{aligned} \nabla \cdot \left((\widetilde{\mathbf{f}} + \mathbf{f}) \tilde{p}_s \right) &= \nabla \cdot (\sigma_{T-s}^2 \nabla p_s) \\ \Rightarrow \widetilde{\mathbf{f}} &= -\mathbf{f} + \sigma_{T-s}^2 \nabla \log \tilde{p}_s \circ \quad \blacksquare \end{aligned}$$

$$d\widetilde{\mathbf{X}}_s = \left(-\mathbf{f}(\widetilde{\mathbf{X}}_s, T-s) + \sigma_{T-s}^2 \nabla \log p(\widetilde{\mathbf{X}}_s, T-s) \right) ds + \sigma_{T-s} d\widetilde{\mathbf{W}}_s \quad (16)$$

梯度項 $\mathbf{s} = \nabla \log p$ 引導著 $\widetilde{\mathbf{X}}_s$ 的機率密度往高機率是有意義的圖片的方向移動。
此即對應「朗之萬動力學(Langevin dynamics)」：考慮位能 U 與波茲曼分布

$$p(\mathbf{x}) \propto \exp(-\beta U(\mathbf{x})) , \quad (17)$$

則梯度項形如

$$\nabla \log p(\mathbf{x}) = -\beta \nabla U(\mathbf{x}) . \quad (18)$$

$$d\widetilde{\mathbf{X}}_s = \left(-\mathbf{f}(\widetilde{\mathbf{X}}_s, T-s) + \sigma_{T-s}^2 \nabla \log p(\widetilde{\mathbf{X}}_s, T-s) \right) ds + \sigma_{T-s} d\widetilde{\mathbf{W}}_s \quad (19)$$

倘若只有梯度項，則過程容易落入局部極小值，而錯過全域最小值。但加上布朗運動的擾動後，其中

$$\sigma_T > \sigma_{T-1} > \dots > \sigma_2 > \sigma_1 > \sigma_0,$$

則可以達到模擬退火(simulated annealing)的功能，讓過程有更高機率達到全域最小值。

除了透過引入位能 U 去描述 score 將隨機過程推向低能量、高機率的位置外，亦可從「消息理論(information theory)」的角度去看。

從右側的定義可見 score $s = \nabla \log p$ 即是往「低熵」的方向移動，即 $s = -\nabla h$ 。

此概念與熱力學的熵

$$S = k_B \log \Omega \quad (20)$$

是相同的，因為宏觀態 i 中每個微觀態發生的機率 p_i 滿足 $p_i = 1/\Omega$ ，其中 Ω 為該宏觀態可能對應的微觀態數量。

定義. (消息熵 Information Entropy)

對於機率分布 $X \sim p$ ，定義某事件 x 的驚奇度(surprisal)/消息量(information content)為

$$h(x) = -\log p(x), \quad (21)$$

則該機率分布的消息熵為

$$H(X) = \mathbb{E}_{X \sim p}[-\log p(X)]。 \quad (22)$$

引理. (低熵分布)

固定標準差下，最低熵的連續分布為高斯分布。

- 1 機率分布之間的變動
- 2 擴散模型與朗之萬動力學
- 3 Score-Based 生成式擴散模型
 - Score-Based 擴散模型 ■ DDPM
- 4 結語

用數值模擬的方法去跑該時間反演隨機微分方程即會需要得知 score 函數，因此我們統稱這類方法為 score-based 擴散模型 [SSKKEP21]。




圖: Score-based 擴散模型。圖源: Figure 7 [T26]。

上述時間反演過程中，唯一不知道的參數即是 score。因此，我們可以使用神經網絡 θ 去學習之：

$$\mathbf{s}_{\theta}(\widetilde{\mathbf{X}}_s, T-s) \approx \mathbf{s}(\widetilde{\mathbf{X}}_s, T-s) = \nabla \log p_{T-s}(\widetilde{\mathbf{X}}_s) \circ \quad (23)$$

最直覺的方法是使用以下的損失函數：

$$\theta^* = \arg \min \mathcal{L}(\theta) = \frac{1}{2} \int_0^T \lambda(t) \mathbb{E}_{\mathbf{X}_t \sim p_t} \left[\|\mathbf{s}_{\theta}(\mathbf{X}_t, t) - \nabla \log p_t(\mathbf{X}_t)\|_2^2 \right] dt, \quad (24)$$

然而我們沒有 $\nabla \log p_t$ 的公式，故接下來需要在特定假設下考慮此問題，例如在 DDPM 的設定下考慮。

在 DDPM 的正序過程為高斯加噪過程：給定 $0 < \beta_t \ll 1$ ，

$$p(\mathbf{x}_t | \mathbf{x}_{t-1}) = \mathcal{N} \left(\mathbf{x}_t; \sqrt{1 - \beta_t} \mathbf{x}_{t-1}, \beta_t \mathbb{1} \right), \quad (25)$$

亦可透過貝氏定理寫作

$$p(\mathbf{x}_t | \mathbf{x}_0) = \mathcal{N} \left(\mathbf{x}_t; \sqrt{\bar{\alpha}_t} \mathbf{x}_0, (1 - \bar{\alpha}_t) \mathbb{1} \right) \text{ 或} \quad (26)$$

$$\mathbf{X}_t = \sqrt{\bar{\alpha}_t} \mathbf{X}_0 + \sqrt{1 - \bar{\alpha}_t} \boldsymbol{\epsilon}, \quad (27)$$

其中 $\boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbb{1})$ 和

$$\bar{\alpha}_t = \prod_{k=1}^t (1 - \beta_k). \quad (28)$$

可以見得 $\bar{\alpha}_t < \bar{\alpha}_{t-1}$ ，滿足我們對於退火的直覺。

$$\begin{aligned} p(\mathbf{x}_t|\mathbf{x}_0) &= \mathcal{N}(\mathbf{x}_t; \sqrt{\bar{\alpha}_t}\mathbf{x}_0, (1 - \bar{\alpha}_t)\mathbb{1}) \\ \mathbf{X}_t &= \sqrt{\bar{\alpha}_t}\mathbf{X}_0 + \sqrt{1 - \bar{\alpha}_t}\boldsymbol{\epsilon} \end{aligned}$$

其 score 爲

$$\begin{aligned} \nabla \log p(\mathbf{x}_t) &= \frac{1}{p(\mathbf{x}_t)} \nabla \int p(\mathbf{x}_t|\mathbf{x}_0) p(\mathbf{x}_0) d\mathbf{x}_0 \\ &= \int \nabla (\log p(\mathbf{x}_t|\mathbf{x}_0)) \frac{p(\mathbf{x}_t|\mathbf{x}_0)p(\mathbf{x}_0)}{p(\mathbf{x}_t)} d\mathbf{x}_0 \\ &= \mathbb{E}_{\mathbf{X}_0 \sim p(\cdot|\mathbf{x}_t)} \left[-\frac{\mathbf{x}_t - \sqrt{\bar{\alpha}_t}\mathbf{X}_0}{1 - \bar{\alpha}_t} \right] = \mathbb{E} \left[-\frac{\boldsymbol{\epsilon}}{\sqrt{1 - \bar{\alpha}_t}} \middle| \mathbf{x}_t \right] . \end{aligned}$$

亦即：score 是在估計加入的高斯噪音。

$$-\sqrt{1 - \bar{\alpha}_t} \nabla \log p_t(\mathbf{x}_t) = \mathbb{E}[\boldsymbol{\epsilon} | \mathbf{x}_t]$$

因此，訓練損失函數可寫為

$$\begin{aligned}
 \mathcal{L}(\boldsymbol{\theta}) &= \frac{1}{2} \int_0^T \omega(t) \mathbb{E}_{\mathbf{X}_t} \left[\|\boldsymbol{\epsilon}_{\boldsymbol{\theta}}(\mathbf{X}_t, t) - \mathbb{E}[\boldsymbol{\epsilon} | \mathbf{X}_t]\|_2^2 \right] dt \\
 &= \frac{1}{2} \int_0^T \omega(t) \mathbb{E}_{\mathbf{X}_0, \boldsymbol{\epsilon}} \left[\|\boldsymbol{\epsilon}_{\boldsymbol{\theta}}(\mathbf{X}_t, t) - \boldsymbol{\epsilon}\|_2^2 \right] dt + C \\
 &= \frac{1}{2} \int_0^T \omega(t) \mathbb{E}_{\mathbf{X}_0, \boldsymbol{\epsilon}} \left[\|\boldsymbol{\epsilon}_{\boldsymbol{\theta}}(\sqrt{\bar{\alpha}_t} \mathbf{X}_0 + \sqrt{1 - \bar{\alpha}_t} \boldsymbol{\epsilon}, t) - \boldsymbol{\epsilon}\|_2^2 \right] dt + C.
 \end{aligned} \tag{29}$$

DDPM 的訓練損失函數則是

$$\theta^* = \arg \min \mathcal{L}_{\text{DDPM}}(\boldsymbol{\theta}) = \sum_{t=1}^T \mathbb{E}_{\mathbf{X}_0, \boldsymbol{\epsilon}} \left[\|\boldsymbol{\epsilon}_{\boldsymbol{\theta}}(\sqrt{\bar{\alpha}_t} \mathbf{X}_0 + \sqrt{1 - \bar{\alpha}_t} \boldsymbol{\epsilon}, t) - \boldsymbol{\epsilon}\|_2^2 \right]. \tag{30}$$

$$\mathcal{L}_{\text{DDPM}}(\theta) = \sum_{t=1}^T \mathbb{E}_{\mathbf{X}_0, \epsilon} \left[\left\| \epsilon_{\theta}(\sqrt{\bar{\alpha}_t} \mathbf{X}_0 + \sqrt{1 - \bar{\alpha}_t} \epsilon, t) - \epsilon \right\|_2^2 \right]$$

Algorithm 1 Training

- 1: **repeat**
 - 2: $\mathbf{x}_0 \sim q(\mathbf{x}_0)$
 - 3: $t \sim \text{Uniform}(\{1, \dots, T\})$
 - 4: $\epsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$
 - 5: Take gradient descent step on
 $\nabla_{\theta} \left\| \epsilon - \epsilon_{\theta}(\sqrt{\bar{\alpha}_t} \mathbf{x}_0 + \sqrt{1 - \bar{\alpha}_t} \epsilon, t) \right\|^2$
 - 6: **until** converged
-

圖: DDPM訓練。圖源: [HJA20]。

學到 score 的參數 θ^* 後，可以有反序過程

$$\begin{aligned}
 \mathbf{X}_{t-1} - \mathbf{X}_t &= \int_{T-(t-1)}^{T-t} d\widetilde{\mathbf{X}}_s \\
 &= \int_{t-1}^t \left(- \underbrace{\mathbf{f}(\mathbf{X}_t, t)}_{\frac{1}{2} \frac{\dot{\bar{\alpha}}_t}{\bar{\alpha}_t} \mathbf{X}_t} + \underbrace{\sigma_t^2}_{-\frac{\dot{\bar{\alpha}}_t}{\bar{\alpha}_t} - \frac{1}{\sqrt{1-\bar{\alpha}_t}}} \underbrace{\mathbf{s}_{\theta^*}(\mathbf{X}_t, t)}_{\boldsymbol{\epsilon}_{\theta^*}(\mathbf{X}_t, t)} \right) dt + \int_{T-(t-1)}^{T-t} \sigma_{T-s} d\widetilde{\mathbf{W}}_s \\
 &\approx \frac{1}{2} \log \left(\frac{\bar{\alpha}_{t-1}}{\bar{\alpha}_t} \right) \mathbf{X}_t - \frac{\boldsymbol{\epsilon}_{\theta^*}(\mathbf{X}_t, t)}{\sqrt{1-\bar{\alpha}_t}} \log \left(\frac{\bar{\alpha}_{t-1}}{\bar{\alpha}_t} \right) + \sqrt{\log \left(\frac{\bar{\alpha}_{t-1}}{\bar{\alpha}_t} \right)} \mathbf{Z} \\
 &= -\frac{1}{2} \log(1 - \beta_t) \mathbf{X}_t - \frac{-\log(1 - \beta_t)}{\sqrt{1-\bar{\alpha}_t}} \boldsymbol{\epsilon}_{\theta^*}(\mathbf{X}_t, t) + \sqrt{-\log(1 - \beta_t)} \mathbf{Z}
 \end{aligned}$$

此為反序過程在「歐拉-丸山(Euler—Maruyama)法」下的一階展開。

承上，

$$\begin{aligned}
 \mathbf{X}_{t-1} &= \left(1 - \frac{1}{2} \log(1 - \beta_t)\right) \mathbf{X}_t - \frac{-\log(1 - \beta_t)}{\sqrt{1 - \bar{\alpha}_t}} \boldsymbol{\epsilon}_{\theta^*}(\mathbf{X}_t, t) + \sqrt{-\log(1 - \beta_t)} \mathbf{Z} \\
 &= \frac{1}{\sqrt{1 - \beta_t}} \left(\mathbf{X}_t - \frac{\beta_t}{\sqrt{1 - \bar{\alpha}_t}} \boldsymbol{\epsilon}_{\theta^*}(\mathbf{X}_t, t) \right) + o(\beta_t) \\
 &\quad + \left(\sqrt{\frac{1 - \bar{\alpha}_{t-1}}{1 - \bar{\alpha}_t}} \beta_t (1 + O(\beta_t)) \right) \mathbf{Z}
 \end{aligned}$$

而 DDPM 所採用的反序過程為

$$\boxed{\mathbf{X}_{t-1} = \frac{1}{\sqrt{1 - \beta_t}} \left(\mathbf{X}_t - \frac{\beta_t}{\sqrt{1 - \bar{\alpha}_t}} \boldsymbol{\epsilon}_{\theta^*}(\mathbf{X}_t, t) \right) + \sqrt{\frac{1 - \bar{\alpha}_{t-1}}{1 - \bar{\alpha}_t}} \beta_t \mathbf{Z}}, \quad (31)$$

兩者在 β_t 的一階項下重合。

由以上推論可知：

- ▶ DDPM 為時間反演隨機過程的一階近似；
- ▶ 另外，DDPM 的反序過程的平均值亦為正序過程的後驗機率 $q(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{x}_0)$ 的平均值。

Algorithm 2 Sampling

```
1:  $\mathbf{x}_T \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$   
2: for  $t = T, \dots, 1$  do  
3:    $\mathbf{z} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$  if  $t > 1$ , else  $\mathbf{z} = \mathbf{0}$   
4:    $\mathbf{x}_{t-1} = \frac{1}{\sqrt{\alpha_t}} \left( \mathbf{x}_t - \frac{1-\alpha_t}{\sqrt{1-\bar{\alpha}_t}} \boldsymbol{\epsilon}_{\theta}(\mathbf{x}_t, t) \right) + \sigma_t \mathbf{z}$   
5: end for  
6: return  $\mathbf{x}_0$ 
```

圖：DDPM抽樣。圖源：[\[HJA20\]](#)。

- 1 機率分布之間的變動
- 2 擴散模型與朗之萬動力學
- 3 Score-Based 生成式擴散模型
- 4 結語

物理學中既有的發展理論在電機等工程領域中有著諸多應用。除了可以用隨機過程的方式去詮釋生成式模型，我們得知

- ▶ 在退火的過程中，系統會發生相變(phase transition) [A24]；
- ▶ 由此觀察可以設計新的算法以減少運算、提升表現 [RA23]。

其他物理與學習理論相交的範例還包括：

1. 易辛模型(Ising model)與訊息傳遞(message passing)；
2. 古典動力學與神經網絡的訓練動力學與穩定性；
3. 費曼圖、隨機矩陣理論與無窮寬神經網絡(詳見 NTK 理論)；
4. ...。

除了 score-based 方法如 DDPM 或是 score-matching，尚有許多建構生成式模型的方法值得探索，諸如 reverse ODEs 和 flow matching 等(詳見 [FW26])。




圖: Score-based 擴散模型。圖源: Figure 7 [T26]。

「Fun Physics — 生成式擴散模型的物理」到此結束！

- [HJA20] Jonathan Ho, Ajay Jain, and Pieter Abbeel. *Denoising Diffusion Probabilistic Models*. 2020. arXiv: 2006.11239 [cs.LG]. URL: <https://arxiv.org/abs/2006.11239>.
- [SE20] Yang Song and Stefano Ermon. *Generative Modeling by Estimating Gradients of the Data Distribution*. 2020. arXiv: 1907.05600 [cs.LG]. URL: <https://arxiv.org/abs/1907.05600>.
- [FW26] Jiayi Fu and Yuxia Wang. *A Tutorial on Diffusion Theory: From Differential Equations to Diffusion Models*. 2026. arXiv: 2605.22586 [cs.LG]. URL: <https://arxiv.org/abs/2605.22586>.
- [T26] Sophia Tang. *Foundations of Schrödinger Bridges for Generative Modeling*. 2026. arXiv: 2603.18992 [cs.LG]. URL: <https://arxiv.org/abs/2603.18992>.

- [SSKKEP21] Yang Song, Jascha Sohl-Dickstein, Diederik P. Kingma, Abhishek Kumar, Stefano Ermon, and Ben Poole. *Score-Based Generative Modeling through Stochastic Differential Equations*. 2021. arXiv: 2011.13456 [cs.LG]. URL: <https://arxiv.org/abs/2011.13456>.
- [SME22] Jiaming Song, Chenlin Meng, and Stefano Ermon. *Denoising Diffusion Implicit Models*. 2022. arXiv: 2010.02502 [cs.LG]. URL: <https://arxiv.org/abs/2010.02502>.
- [LZBCLZ22] Cheng Lu, Yuhao Zhou, Fan Bao, Jianfei Chen, Chongxuan Li, and Jun Zhu. *DPM-Solver: A Fast ODE Solver for Diffusion Probabilistic Model Sampling in Around 10 Steps*. 2022. arXiv: 2206.00927 [cs.LG]. URL: <https://arxiv.org/abs/2206.00927>.

- [CVSC22] Guillaume Couairon, Jakob Verbeek, Holger Schwenk, and Matthieu Cord. *DiffEdit: Diffusion-based semantic image editing with mask guidance*. 2022. arXiv: 2210.11427 [cs.CV]. URL: <https://arxiv.org/abs/2210.11427>.
- [A24] Luca Ambrogioni. *The statistical thermodynamics of generative diffusion models: Phase transitions, symmetry breaking and critical instability*. 2024. arXiv: 2310.17467 [stat.ML]. URL: <https://arxiv.org/abs/2310.17467>.
- [RA23] Gabriel Raya and Luca Ambrogioni. *Spontaneous Symmetry Breaking in Generative Diffusion Models*. 2023. arXiv: 2305.19693 [cs.LG]. URL: <https://arxiv.org/abs/2305.19693>.

